

Detekce parazita malárie v krevním nátěru pomocí přenosového učení a metody k nejbližších sousedů

Pracovní šablona miniprojektu — upravte podle vlastního řešení

Jméno Příjmení

Jméno Příjmení

Tým „...“ · Veletrh vědy · Katedra matematiky FJFI ČVUT

14. června 2026

Abstrakt

Malárie každoročně způsobí zhruba 600 000 úmrtí, převážně tam, kde chybí vyškolení patologové schopní rozpoznat parazita pod mikroskopem. Zkoumáme, zda lze tuto úlohu automatizovat: na veřejném datasetu 27 558 mikroskopických snímků jednotlivých červených krvinek (Národní institut zdraví, NIH) rozlišujeme buňky zdravé od napadených parazitem *Plasmodium*. Naše současné řešení nejprve použije zmrazenou konvoluční neuronovou síť ResNet50 jako extraktor příznaků a na získaných vektorech klasifikuje buňky jednoduchou metodou k nejbližších sousedů (k -NN). Tento baseline dosahuje na testovací sadě plochy pod ROC křivkou 0,93. Současně ukazujeme, proč v medicíně nestačí samotná přesnost: při výchozím prahu má model přesnost 0,77, ale senzitivitu jen 0,56 — přehlédne tedy bezmála polovinu nemocných. Tato šablona slouží jako výchozí bod; svůj vlastní, lepší klasifikátor do ní doplníte na vyznačených místech.

1 Úvod a vymezení problému

Malárie zůstává jednou z nejsmrtelnějších infekčních nemocí: podle Světové zdravotnické organizace (World Health Organization, WHO) na ni v roce 2022 zemřelo přibližně 600 000 lidí [1]. Spolehlivá diagnóza se přitom stále opírá o tzv. *tlustou kapku* a *tenký nátěr* krve, kde laborant pod mikroskopem hledá v červených krvinkách parazita *Plasmodium*. Tento postup je pomalý, vyžaduje zkušeného odborníka a právě v oblastech s nejvyšším výskytem malárie takových odborníků zoufale chybí. Vzniká tak otázka, kterou řešíme: *lze rozhodnutí „je tahle buňka napadená?“ spolehlivě svěřit algoritmu?*

Klíčovou překážkou pro klasické strojové učení je, že natrénovat rozpoznávač obrazu od nuly vyžaduje miliony označených snímků a značný výpočetní výkon. Obojí obcházíme pomocí *přenosového učení* (transfer learning): převezmeme síť předtrénovanou na milionech běžných fotografií, využijeme její schopnost „vidět“ tvary a textury, a doučíme jen malou rozhodovací část. Konkrétně v tomto draftu kombinujeme zmrazený extraktor příznaků ResNet50 s klasifikátorem k nejbližších sousedů a na datasetu NIH dosahujeme plochy pod ROC křivkou 0,93; zároveň zdůrazňujeme, že kvalitu medicínského klasifikátoru je nutné posuzovat podle senzitivity a specificity, nikoli podle pouhé přesnosti.

Tento dokument je **pracovní šablona**. Popisuje výchozí řešení a jeho vyhodnocení tak, abyste z něj mohli vyjít a nahradit jej vlastním, vylepšeným postupem. Místa, kde to máte udělat, jsou označena poznámkou „Pro tým“.

Pro tým: do tohoto úvodu doplňte jednou větou, čím se vaše řešení liší od baseline a jakého hlavního výsledku dosahuje.

2 Data

Pracujeme s veřejným datasetem *Malaria Cell Images* amerického Národního institutu zdraví [2]. Obsahuje 27 558 barevných snímků jednotlivých, již vysegmentovaných červených krvinek a je dokonale *vyvážený* — právě polovina buněk je napadená parazitem a polovina zdravá (13 779 a 13 779). Vyváženost je důležitá pro interpretaci výsledků: znamená, že náhodné hádání dává přesnost 50 %, takže každé zlepšení nad tuto hranici pochází ze skutečně naučeného rozdílu.

Aby výsledky poctivě měřily zobecnění na nové buňky, rozdělili jsme data na tři části *stratifikovaně* (se zachováním poměru tříd) a s pevným náhodným zrnem: trénovací sadu (19 289 buněk), ověřovací sadu (4 135 buněk) pro ladění a výběr modelu, a skrytou testovací sadu (4 134 buněk), kterou používáme výhradně pro závěrečné vyhodnocení. Oddělená testovací sada je zásadní: bez ní bychom snadno vyladili model na konkrétní data a přecenili jeho skutečnou kvalitu.

3 Metoda

3.1 Extrakce příznaků zmrazeným ResNet50

Protože nemáme dost dat ani času na trénink konvoluční neuronové sítě (convolutional neural network, CNN) od nuly, použijeme jako *extraktor příznaků* síť ResNet50 [3] předtrénovanou na datasetu ImageNet. Každý snímek buňky nejprve standardně předzpracujeme (změna velikosti na 224×224 obrazových bodů a normalizace barev podle ImageNetu) a poté jím proženeme síť, ze které jsme odebrali poslední klasifikační vrstvu. Výstupem je pro každou buňku vektor **2048 čísel** — tzv. *příznaky*, které shrnují, co se na snímku nachází (tvary, textury, skvrny). Síť přitom necháváme *zmrazenou*: její váhy se neučí, jen překládá obrázek na čísla. Tím se celá úloha redukuje na klasifikaci vektorů, kterou zvládne i slabý počítač během několika sekund.

3.2 Klasifikace metodou k nejbližších sousedů

Jako výchozí klasifikátor jsme zvolili záměrně co nejjednodušší model, abychom získali poctivou *latku* (baseline) ke srovnání: metodu k nejbližších sousedů (k -nearest neighbors, k -NN) [4]. Ta se vlastně vůbec netrénuje — pouze si zapamatuje trénovací příznaky. Novou buňku zařadí tak, že mezi zapamatovanými najde k nejbližších (nejpodobnějších v prostoru příznaků) a nechá je hlasovat, přičemž bližší sousedé mají větší váhu; podíl hlasů pro třídu „napadená“ bereme jako odhad pravděpodobnosti. Použili jsme $k = 31$ sousedů a před výpočtem vzdáleností příznaky standardizovali (nulový průměr, jednotkový rozptyl), protože vzdálenosti dávají smysl jen při srovnatelném měřítku jednotlivých příznaků.

Pro tým: tohle je místo, kde [sekce 3.2](#) nahradíte svým řešením — například malou trénovanou neuronovou sítí. Popište jeho architekturu a jak jste ho ladili.

4 Vyhodnocení

4.1 Proč samotná přesnost nestačí

V medicíně mají dva druhy chyb zcela odlišnou cenu, a proto kvalitu klasifikátoru neměříme pouhou *přesností* (accuracy, podíl správně zařazených buněk). Označme jako pravdivě pozitivní (true positive, TP) napadené buňky správně označené, falešně negativní (false negative, FN) napadené buňky chybně prohlášené za zdravé, falešně pozitivní (false positive, FP) zdravé buňky chybně označené

Tabulka 1: Výsledky na skryté testovací sadě (4 134 buněk). Přesnost, senzitivita a specificita jsou uvedeny při výchozím prahu 0,5; soutěžní metrika je specificita při senzitivitě ≥ 99 %. Hodnoty jsou z jednoho deterministického běhu.

Metoda	Přesnost	Senzitivita	Specificita	Spec. @sens. 99 %	AUC
ResNet50 + k -NN (baseline)	0,77	0,56	0,99	0,00	0,93
Vaše řešení	—	—	—	—	—

za napadené a pravdivě negativní (true negative, TN) správně propuštěné zdravé buňky. Z nich definujeme dvě klíčové veličiny:

$$\text{senzitivita} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{specificita} = \frac{\text{TN}}{\text{TN} + \text{FP}}. \quad (1)$$

Senzitivita říká, jaký podíl skutečně nemocných model zachytí; nízká senzitivita znamená přehlížené pacienty, což může stát život. Specificita říká, jaký podíl zdravých model správně propustí; nízká specificita znamená zbytečné falešné poplachy. Tyto dvě veličiny se navzájem vyměňují podle zvoleného *prahu*, nad kterým buňku prohlásíme za napadenou; celý kompromis zachycuje ROC křivka (receiver operating characteristic) a souhrnně plocha pod ní (area under the curve, AUC).

Jako hlavní **soutěžní metriku** jsme zvolili *specificitu při senzitivitě ≥ 99 %*. U smrtelné nemoci je totiž nepodkročitelným požadavkem „nepřehlédnout nemocného“, proto fixujeme senzitivitu vysoko (zachytit aspoň 99 % napadených) a soutěžíme v tom, kdo přitom udrží nejvyšší specificitu, tedy nejméně falešných poplachů. Odpovídá to bodu na ROC křivce při senzitivitě 99 %.

4.2 Protokol


Klasifikátor „natrénujeme“ (u k -NN pouze zapamatujeme) na trénovací sadě, případnou volbu prahu provádíme na ověřovací sadě a všechna níže uvedená čísla měříme na skryté testovací sadě (4 134 buněk), kterou model při učení nikdy nevidí. Metoda k -NN je deterministická, proto uvádíme výsledky jednoho běhu.

4.3 Výsledky

Výsledky baseline shrnuje [tabulka 1](#). Nejnázornější je přitom rozpor mezi přesností a senzitivitou: při výchozím prahu 0,5 dosahuje k -NN přesnosti 0,77, ale senzitivity jen 0,56 — jak ukazuje matice záměn na [obrázek 1](#), přehlédne 904 z 2067 napadených buněk. Vysoká specificita (0,99) tu tedy maskuje, že model propustí téměř polovinu nemocných; samotná přesnost by nás obelhala. Teprve pohled na celou ROC křivku ([obrázek 2](#)) ukazuje, že schopnost *seřadit* buňky není špatná: plocha pod ní je 0,93. Naše soutěžní metrika je ale přísnější. Požadujeme zachytit aspoň 99 % nemocných, a při této podmínce klesá specificita k -NN na 0,00 — aby chytil 99 % napadených, musel by práh posunout tak nízkou, že označí prakticky všechny buňky. Požadovanou senzitivitu tedy k -NN splní, ale s nulovou specificitou — tedy prakticky bezcenně; právě to je důvod naučit lepší model (váš úkol).

5 Diskuse

Slabší výsledek k -NN není náhoda, ale důsledek dvou jevů, které stojí za zmínku. Zaprvé, ve 2048-rozměrném prostoru příznaků přestávají být vzdálenosti spolehlivé — všechny body se stávají přibližně stejně vzdálené, takže pojem „nejbližší soused“ ztrácí ostrost (tzv. *prokletí dimenzionality*).



Obrázek 1: Matice záměn k -NN baseline na testovací sadě při prahu 0,5. Řádky jsou skutečné třídy, sloupce predikce. Pravý dolní roh (1163) jsou správně zachycení nemocní, levý dolní roh (904) jsou *přehlédnutí* nemocní — nejdražší typ chyby.

Zadruhé, k -NN se nic neučí: nedokáže zvážit, které z 2048 příznaků jsou pro rozlišení parazita důležité, a bere je všechny stejně. Právě tady má prostor lépe informovaný model, který se naučí, na čem záleží.

Nezávisle na použitém modelu zůstávají dvě praktická omezení. Skutečné nasazení by se setkalo s *doménovým posunem* — jiný mikroskop, jiné barvení nebo jiná populace pacientů by mohly přesnost snížit oproti našemu datasetu. A protože cena přehlédnutého nemocného je vyšší než cena falešného poplachu, je v praxi vhodnější model spíše jako nástroj, který lékaře *upozorní*, než jako konečný rozhodčí.


Pro tým: sem patří rozbor vašich výsledků — co fungovalo, co ne, o kolik jste překonali baseline a čím to vysvětlujete.

6 Závěr

Ukázali jsme, že zmrazený ResNet50 jako extraktor příznaků v kombinaci s jednoduchým klasifikátorem k nejbližších sousedů dosahuje na datasetu NIH plochy pod ROC křivkou 0,93, a zdůraznili jsme, proč je v medicíně nutné hodnotit senzitivitu a specificitu, nikoli pouhou přesnost. Tento baseline je výchozím bodem, který má vaše řešení překonat — zejména udržet co nejvyšší specificitu při požadované senzitivě 99 %.

Reference

- [1] World Health Organization. World Malaria Report 2023, 2023.



Obrázek 2: ROC křivka k -NN baseline na testovací sadě. Vodorovná čára značí požadovanou senzitivitu 99 %; soutěžní metrika je nejvyšší specifická dosažitelná nad touto čarou. Baseline jí dosahuje až při téměř 100 % falešně pozitivním poměru (specifická ≈ 0).

- [2] Sivaramakrishnan Rajaraman, Sameer K. Antani, Mahdih Poostchi, Kamolrat Silamut, Md A. Hossain, Richard J. Maude, Stefan Jaeger, and George R. Thoma. Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images. *PeerJ*, 6:e4568, 2018.
- [3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep Residual Learning for Image Recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [4] Thomas M. Cover and Peter E. Hart. Nearest Neighbor Pattern Classification. *IEEE Transactions on Information Theory*, 13(1):21–27, 1967.